

Estructura Productiva y Cicatriz COVID-19

Tipología Composicional (CLR/ILR) y Econometría de Panel en los 24 Departamentos del Perú

Círculo de Ciencia de Datos y Econometría

Mapa de la Investigación y Tesis Central

1. Motivación, Datos e Hipótesis Estructural
2. Geometría Composicional (CoDa) y Tipología Productiva
3. Régimen de Volatilidad Estructural e Ilusión del Efecto Base
4. Evidencia en Niveles Indexados y Efecto Cicatriz (Scarring Effect)
5. Conclusiones, Implicancias y Reproducibilidad

Tesis Central (Top-Down Takeaway)

El choque de 2020 paralizó transversalmente todas las regiones ($\approx -14{,}4\,\%$), pero la **hiper-especialización en enclaves mineros** multiplicó por $4{,}4\times$ la volatilidad histórica y generó una **cicatriz pospandemia de** $-10{,}92$ **puntos** ($p = 0{,}0029$) entre 2021 y 2023.

Cobertura Empírica

INEI: 24 departamentos, periodo 2008–2025 ($N = 428$ obs. de panel; 12 sectores productivos).

Arsenal Metodológico

CoDa (Aitchison CLR/ILR) + PCA + Ward/K-Means/PAM/GMM + Panel FE con errores clusterizados.

El Dilema Regional ante el Choque COVID-19 (SCQA)

Marco Estructural SCQA

- **Situación (S):** Los 24 departamentos exhiben fuerte heterogeneidad productiva, desde enclaves mineros ($> 40\,\%$) hasta economías urbanas.
- **Complicación (C):** En 2020 el PIB colapsó, pero los modelos en tasas anuales ($\Delta\,\%$PIB) sugerían un impacto indiferenciado ($p > 0{,}20$).
- **Pregunta (Q):** ¿Fue el choque neutral a la estructura productiva o las tasas anuales ocultan una cicatriz acumulada asimétrica?
- **Respuesta (A):** Al aplicar CoDa (CLR) y pasar a **niveles indexados (PIB$_{2019=100}$)**, emerge un rezago pospandemia significativo al $1\,\%$ en los enclaves.

Arquitectura de la Base Consolidada (INEI)

Dimensión del Panel	Magnitud
Unidades transversales (N)	**24 departamentos**
Horizonte temporal (T)	**2008–2025 (18 años)**
Observaciones totales	**428 filas de panel**
Ventana pre-shock (Clustering)	**2015–2019 (5 años)**
Ventana ciclo COVID (Niveles)	**2017–2023 (100 % bal.)**
Ramas de actividad VAB	**12 sectores (suma 100 %)**

So What?: Clasificar con el promedio 2015–2019 garantiza **exogeneidad estricta** frente al shock de 2020.

Fuente: INEI – Cuentas Nacionales Departamentales (Cuadros 1 y 2, precios constantes de 2007).

Geometría del Simplex: Transformación CLR y PCA

1. Cierre Composicional ($\mathcal{S}^D$): Las participaciones sectoriales suman $100\,\%$, induciendo correlaciones negativas espurias en el espacio crudo.

2. Reemplazo Multiplicativo: Lambayeque y San Martín registran $0\,\%$ en minería (2015–19). Se imputa $\delta = 0{,}05\,\%$ reescalando los sectores positivos:

$$x_{ij}^{*} = \delta \ (\text{si } x_{ij} = 0); \quad x_{ij}\left(1 - \tfrac{z_i \delta}{100}\right)$$

3. Coordenadas Log-Ratio Centradas (CLR) con media geométrica $g_i = \left(\prod_{j=1}^{D} x_{ij}^{*}\right)^{1/D}$:

$$\operatorname{clr}(x_i^{*}) = \left[\ln \tfrac{x_{i1}^{*}}{g_i}, \ldots, \ln \tfrac{x_{iD}^{*}}{g_i}\right]$$

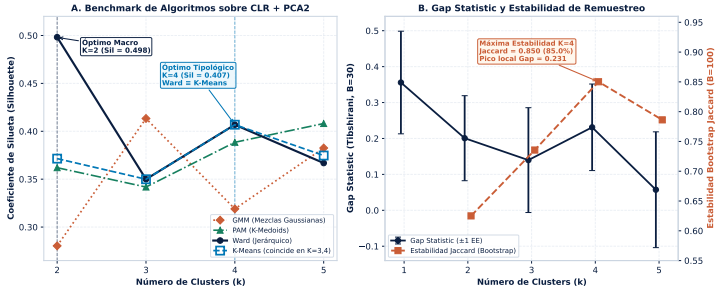
Varianza y Loadings PCA

Sector / Métrica	PC1	PC2	PC3
Varianza Explicada	**51.65 %**	**20.02 %**	**15.71 %**
Varianza Acumulada	**51.65 %**	**71.68 %**	**87.39 %**
Extracción Minera e Hidroc.	**+0.906**	+0.137	−0,241
Electricidad, Gas y Agua	+0.145	−0,289	**+0.825**
Agricultura y Ganadería	−0,130	−0,542	−0,373
Manufactura	−0,152	**+0.630**	+0.212
Comercio	−0,181	+0.016	−0,216
Telecom. y Serv. Info.	−0,202	+0.217	−0,149

Lectura: **PC1** mide intensidad extractiva minera (+0.91); **PC2** opone manufactura (+0.63) contra agro (−0,54).

Fuente: Aitchison (1986); Martín-Fernández et al. (2003). Cálculos en `clustering_paso1.py`.

Validación: CLR+PCA2 Maximiza Silueta y Estabilidad

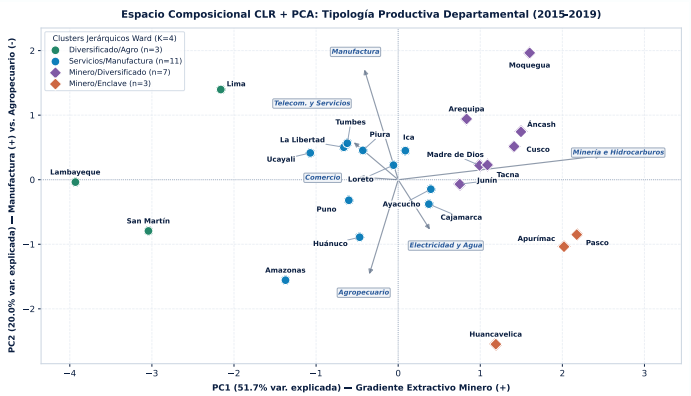


Convergencia (48 modelos): En $K = 4$ sobre CLR+PCA2, **Ward** y **K-Means** producen la misma partición (Silueta = $0{,}407$, CH = $22{,}24$), superando a PAM ($0{,}389$) y GMM ($0{,}319$).

Doble Óptimo: $K = 2$ lidera en silueta ($0{,}498$) y $K = 4$ maximiza estabilidad Jaccard ($85{,}0\,\%$–$87{,}7\,\%$).

Fuente: Tibshirani et al. (2001) para Gap Statistic ($B = 30$); Hennig (2007) para estabilidad Jaccard ($B = 100$).

Mapa Estructural: Cuatro Perfiles en CLR + PCA



Geometría de los 4 Clusters

♦ **Minero/Enclave** ($n = 3$)**:**
Apurímac, Pasco y Huancavelica (alta extracción + energía).

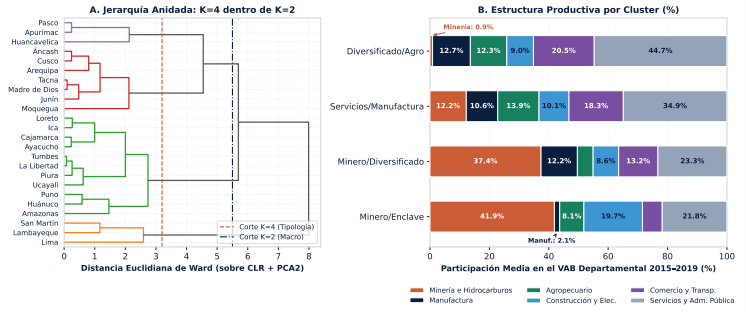
♦ **Minero/Diversificado** ($n = 7$)**:**
Moquegua, Áncash, Cusco, Arequipa, Tacna, Madre de Dios y Junín.

• **Servicios/Manufactura** ($n = 11$)**:**
Núcleo central (Ica, La Libertad, Piura, Cajamarca, Puno, etc.).

• **Diversificado/Agro** ($n = 3$)**:**
Lima, Lambayeque y San Martín en el extremo no minero ($PC1 < -2$).

Fuente: Elaboración propia sobre el promedio composicional 2015–2019 (`modelo-clusters.ipynb`).

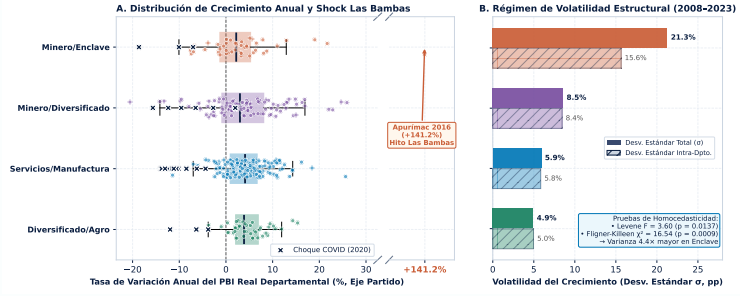
Anatomía Jerárquica: $K = 4$ Anidado dentro de $K = 2$



Anidamiento exacto de Ward: Los 4 clusters se agrupan sin cruces en dos bloques macroeconómicos: **Bloque Minero** ($N = 10$: *Enclave* $41{,}9\,\%$ minería + *Minero/Div.* $37{,}4\,\%$ minería) vs. **Bloque Diversificado** ($N = 14$: *Serv./Manuf.* $12{,}2\,\%$ + *Div./Agro* $0{,}9\,\%$).

Fuente: Resultados en `clustering_paso4_perfil_K4.xlsx` y `econ_reagrupa.py`.

Riesgo Regional: Enclaves Exhiben $4{,}4\times$ Más Volatilidad



Heterocedasticidad verificada: El test de **Levene** ($F = 3{,}97, p = 0{,}0083$) y **Fligner-Killeen** ($\chi^2 = 17{,}54, p = 0{,}0005$) confirman varianzas dispares ($\sigma = 20{,}5\,\%$ en Enclave vs. $4{,}6\,\%$ en Agro).

Shock Las Bambas (2016): Apurímac creció $+141{,}2\,\%$ en un año, inflando la varianza residual en tasas.

Fuente: Panel 2008–2025 ($N = 428$). Pruebas de varianza ejecutadas en `modelo-econometrico.ipynb`.

El Puzzle de las Tasas Anuales (Modelos M1–M4)

Panel FE sobre Crecimiento Anual (var_pib$_{it}$, 2008–2025)

Variable / Estadístico	M1 ($K=4$)	M2 (Macro)	M3 (+Rebote)	M4 (Sin Apu16)
Intercepto ($\hat{\alpha}$)	$4{,}53^{***}$	$4{,}53^{***}$	$4{,}12^{***}$	$4{,}19^{***}$
COVID$_{2020}$ (Base)	$-11{,}95^{***}$	$-14{,}43^{***}$	$-13{,}97^{***}$	$-14{,}43^{***}$
REBOTE$_{2021}$ (Base)	—	—	$+7{,}80^{***}$	—
COVID × Serv./Manuf.	$-2{,}90$ (0.20)	—	—	—
COVID × Minero/Div.	$-1{,}70$ (0.64)	—	—	—
COVID × Minero/Enclave	$-5{,}73$ (0.13)	—	—	—
COVID × Macro Minero	—	$-0{,}63$ (0.81)	$-0{,}75$ (0.77)	$+0{,}28$ (0.91)
REBOTE × Macro Minero	—	—	$-2{,}11$ (0.45)	—
Observaciones (N)	428	428	428	427
R^2 Within	0.1390	0.1376	0.1691	**0.2620**
Poolability F (p-valor)	0.96 (0.51)	0.92 (0.57)	0.96 (0.52)	1.07 (0.38)

Nota: p-valores con errores estándar clusterizados entre paréntesis. $^{***}p < 0{,}01$.

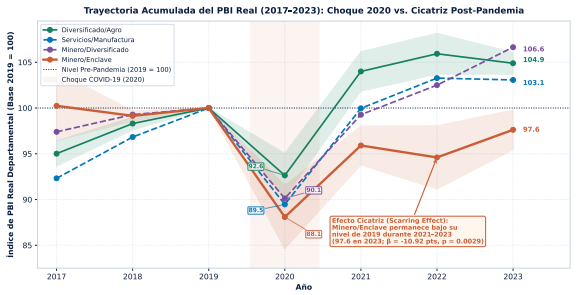
Fuente: Estimaciones con `linearmodels.PanelOLS` en `econ_paso1.py` a `econ_paso3.py`.

Diagnóstico del Puzzle

1. **Parálisis transversal (Q2-2020):** El confinamiento detuvo tanto la gran minería como el comercio ($\approx -14{,}4\,\%$).
2. **Ruido pre-pandemia:** En M4, excluir solo *Apurímac 2016* casi duplica el R^2_{within} ($13{,}8\,\% \rightarrow 26{,}2\,\%$).
3. **Ilusión del efecto base:** Caer $-12\,\%$ en 2020 y crecer $+9\,\%$ en 2021 luce positivo en var_pib, pero deja al PIB en $95{,}9\,\%$ del nivel de 2019.

Solución: Modelar el **nivel acumulado indexado (PIB$_{2019=100}$)**.

Trayectoria Indexada ($PIB_{2019=100}$): Cicatriz en Enclaves



Divergencia 2021–2023: *Diversificado/Agro* (104,9), *Minero/Div.* (106,6) y *Serv./Manuf.* (103,1) superaron el nivel de 2019; **Minero/Enclave quedó bajo 100 todo el trienio (**$95{,}9 \rightarrow 94{,}6 \rightarrow 97{,}6$**)**.

Mecanismo: Conflictividad en el Corredor Minero y baja articulación local frenaron la recuperación.

Fuente: Panel balanceado 2017–2023 ($N = 24, T = 7$, Obs $= 168$). Elaboración propia (`generar_analisis_completo.py`).

Modelos en Nivel Indexado (M5–M6): Cicatriz al 1 %

Dependiente: Índice de PIB Real ($\text{PIB}_{i,2019} = 100$, 2017–2023)

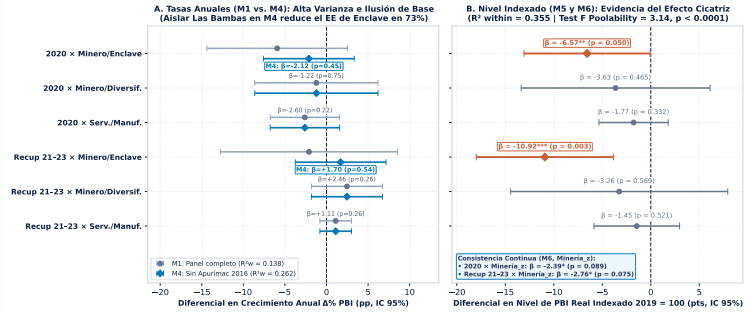
	M5: Clusters ($K = 4$)		M6: Continuo (Minería$_z$)	
Regresor (Efectos Fijos)	**Beta**	**p-valor**	**Beta**	**p-valor**
Intercepto (Senda Pre-COVID)	$97{,}71^{***}$	0.0000	$97{,}71^{***}$	0.0000
COVID_{2020} (Ref: Div./Agro)	$-5{,}14^{***}$	0.0016	$-7{,}83^{***}$	0.0000
$\text{POST}_{2021\text{–}23}$ (Ref: Div./Agro)	$+7{,}17^{***}$	0.0000	$+4{,}19^{**}$	0.0224
$\text{COVID}_{2020} \times$ Serv./Manuf.	$-1{,}77$	0.3318	—	—
$\text{COVID}_{2020} \times$ Minero/Div.	$-3{,}63$	0.4655	—	—
$\text{COVID}_{2020} \times$ Minero/Enclave	$\mathbf{-6{,}57^{**}}$	**0.0495**	—	—
$\text{POST}_{2021\text{–}23} \times$ Serv./Manuf.	$-1{,}45$	0.5212	—	—
$\text{POST}_{2021\text{–}23} \times$ Minero/Div.	$-3{,}26$	0.5694	—	—
$\text{POST}_{2021\text{–}23} \times$ Minero/Enclave	$\mathbf{-10{,}92^{***}}$	**0.0029**	—	—
$\text{COVID}_{2020} \times$ Minería$_z$ (1 SD)	—	—	$\mathbf{-2{,}39^{*}}$	**0.0891**
$\text{POST}_{2021\text{–}23} \times$ Minería$_z$ (1 SD)	—	—	$\mathbf{-2{,}76^{*}}$	**0.0747**
Observaciones / Departamentos	168 / 24		168 / 24	
R^2 Within	**0.3554**		**0.3451**	
Test F Poolability (p-valor)	**3.14** ($p < 0{,}0001$)		**3.29** ($p < 0{,}0001$)	

Salto Econométrico

- **Efectos fijos validados:** El test de Poolability pasa de $p = 0{,}51$ (en tasas) a $p < 0{,}0001$ en niveles indexados.
- **Mayor ajuste:** El R^2_{within} sube de $13{,}9\,\%$ a $35{,}5\,\%$.
- **Doble golpe al Enclave (M5):** Caída adicional de $-6{,}57$ **pts** en 2020 ($p = 0{,}0495$) y rezago acumulado de $-10{,}92$ **pts** en 2021–2023 ($p = 0{,}0029$).
- **Gradiente continuo (M6):** $+1$ SD en minería reduce el nivel pospandemia en $-2{,}76$ **pts** ($p = 0{,}075$).

Fuente: Estimaciones PanelOLS con efectos fijos de entidad y errores estándar clusterizados (`resumen_modelos_econometricos.xlsx`).

Contraste de Modelos: Tasas Anuales vs. Niveles



Lección metodológica: Evaluar choques estructurales mediante variaciones interanuales aisladas (Panel A) induce un **error Tipo II** (falso negativo). La especificación en nivel acumulado $\text{PIB}_{2019=100}$ (Panel B) revela la persistencia real del daño productivo.

Fuente: Intervalos de confianza al 95 % basados en errores estándar robustos agrupados por departamento.

Conclusiones e Implicancias de Política Regional

Hallazgos Empíricos Centrales

1. **Jerarquía dual ($K = 4 \subset K = 2$):** CLR+PCA2 divide al país en un bloque Minero ($N = 10$) y uno Diversificado ($N = 14$), subdivididos con $85\,\%$ de estabilidad bootstrap en 4 perfiles.
2. **Minería Diversificada vs. Enclave:** *Minero/Div.* (Arequipa, Moquegua, Cusco) superó su nivel pre-COVID ($106{,}6$ en 2023), pero *Minero/Enclave* (Apurímac, Pasco, Huancavelica) sufrió una cicatriz de $-10{,}92$ pts ($p = 0{,}0029$).
3. **Trampa de volatilidad:** Los enclaves soportan una volatilidad ($\sigma = 20{,}5\,\%$) $4{,}4\times$ mayor que el grupo agro/servicios ($\sigma = 4{,}6\,\%$).

Agenda de Política Regional

- **Encadenamientos en enclaves:** Invertir canon en Apurímac, Pasco y Huancavelica en agroindustria y logística que amortigüen paros extractivos.
- **Fondos de estabilización:** Reglas contracíclicas en clusters con $\sigma > 15\,\%$ para suavizar inversión pública.
- **Métrica en niveles:** Evaluar desempeño con índices acumulados ($\text{PIB}_{2019=100}$) en vez de tasas anuales.

Mensaje Final: La fragilidad pospandemia proviene de la **falta de diversificación** en economías de enclave.

Fuente: Síntesis del equipo de investigación – Círculo de Ciencia de Datos y Econometría (CCDE).

Trazabilidad Reproducible y Referencias Clave

Arquitectura del Repositorio

Módulo / Archivo	Función en el Pipeline
`src/generador-df.py`	ETL de 24 Excels INEI → panel base
`src/clustering_paso1..4.py`	Ceros $\delta = 0{,}05$, CLR/ILR, PCA y Gap
`src/econ_paso1..3.py`	Modelos en tasas y diagnóstico $K = 2$
`src/generar_analisis_completo.py`	Modelos M1–M6 en niveles y 6 figuras
`src/modelo-clusters.ipynb`	Cuaderno ejecutable de tipología CoDa
`src/modelo-econometrico.ipynb`	Cuaderno ejecutable de Panel FE
`data/processed/*.xlsx`	Bases (`panel_econometrico_final`)

Reproducibilidad: Semilla fija (`RANDOM_STATE = 0`), entorno declarativo en `requirements.txt` y trazabilidad en Git.

Referencias Metodológicas Clave

Aitchison, J. (1986). *The Statistical Analysis of Compositional Data*. Chapman & Hall.

Martín-Fernández, J. A. et al. (2003). Dealing with zeros in compositional data sets. *Math. Geol.*, 35(3), 253–278.

Tibshirani, R., Walther, G. & Hastie, T. (2001). Estimating the number of clusters via the gap statistic. *JRSS-B*, 63(2), 411–423.

Wooldridge, J. M. (2010). *Econometric Analysis of Cross Section and Panel Data*. MIT Press.

INEI (2025). *Producto Bruto Interno por Departamentos 2007–2025*. Lima.

Fuente: Repositorio oficial: `https://github.com/CCDE-DataLab/clusters-departamentales`.